

Análisis y predicción del desempleo en Costa Rica mediante econometría y Machine Learning

Resumen ejecutivo

El presente proyecto analiza la relación entre desempleo, inflación y crecimiento del Producto Interno Bruto (PIB) en Costa Rica mediante el uso de herramientas econométricas y modelos de Machine Learning desarrollados en Python. El estudio utiliza datos obtenidos desde la API del Banco Mundial y combina un enfoque explicativo con uno predictivo.

En una primera etapa, se estimó un modelo de regresión lineal múltiple (OLS) para evaluar la relación estadística entre las variables macroeconómicas. Posteriormente, se desarrollaron modelos predictivos utilizando regresión lineal con rezagos temporales y Random Forest, aplicando validación temporal para evaluar el desempeño fuera de muestra.

Los resultados muestran que la inflación y el crecimiento del PIB presentan relaciones estadísticamente significativas con el desempleo. Asimismo, el modelo lineal que incorpora un rezago del desempleo (**lag1**) fue el de mejor desempeño predictivo, superando tanto al modelo base como a Random Forest. Esto sugiere que, para este conjunto de datos, una estructura lineal con memoria temporal captura de mejor manera la dinámica del desempleo que modelos más complejos.

1. Introducción

El desempleo constituye una de las variables más relevantes para el análisis económico y social, debido a sus implicaciones sobre el crecimiento económico, la estabilidad política y el bienestar de la población. Comprender los factores asociados a su comportamiento y desarrollar herramientas predictivas confiables resulta fundamental para el diseño de políticas públicas y la toma de decisiones.

Tradicionalmente, el desempleo ha sido estudiado mediante herramientas econométricas que buscan identificar relaciones causales entre variables macroeconómicas. Sin embargo, el avance de la ciencia de datos y el Machine Learning ha abierto nuevas posibilidades para complementar estos enfoques mediante modelos predictivos más flexibles.

En este contexto, el presente proyecto busca integrar ambas perspectivas mediante el uso de Python para desarrollar un análisis aplicado al caso de Costa Rica.

2. Planteamiento del problema

El desempleo responde a múltiples factores económicos y estructurales. Entre las variables más comúnmente asociadas a su comportamiento se encuentran la inflación y el crecimiento económico.

El presente proyecto busca responder las siguientes preguntas:

1. ¿Qué relación existe entre inflación, crecimiento del PIB y desempleo en Costa Rica?
2. ¿Qué tan bien puede predecirse el desempleo utilizando modelos econométricos y de Machine Learning?
3. ¿Un modelo más complejo como Random Forest mejora el desempeño predictivo respecto a modelos lineales con memoria temporal?

3. Objetivos

Objetivo general

Analizar y predecir el desempleo en Costa Rica utilizando herramientas econométricas y modelos de Machine Learning en Python.

Objetivos específicos

- Extraer y procesar datos macroeconómicos desde la API del Banco Mundial.
- Analizar la relación entre desempleo, inflación y crecimiento del PIB.
- Construir modelos econométricos de regresión lineal múltiple.
- Implementar modelos predictivos utilizando Machine Learning.
- Comparar el desempeño predictivo de distintos modelos.

4. Fuente de datos

Los datos utilizados fueron obtenidos mediante la API del Banco Mundial para Costa Rica.

Las variables empleadas fueron:

Variable	Indicador
Desempleo	Total unemployment (% of total labor force)
Inflación	Inflation, consumer prices (annual %)
Crecimiento del PIB	GDP growth (annual %)

Los datos fueron procesados en Python utilizando las librerías [requests](#), [pandas](#) y [numpy](#).

5. Metodología

5.1 Extracción y limpieza de datos

Los datos fueron obtenidos mediante solicitudes HTTP a la API del Banco Mundial. Posteriormente, se construyeron Data Frames individuales para cada variable y se unificaron en un único conjunto de datos utilizando el año como variable de unión.

Durante el proceso se eliminaron valores faltantes y se reorganizó el dataset cronológicamente.

5.2 Análisis exploratorio

Se realizó una matriz de correlación para identificar relaciones preliminares entre las variables.

Los resultados mostraron:

- correlación negativa entre desempleo e inflación,
- correlación negativa entre desempleo y crecimiento del PIB,
- Correlación positiva moderada entre inflación y crecimiento del PIB.

5.3 Regresión econométrica

Se estimó un modelo de regresión lineal múltiple utilizando Ordinary Least Squares (OLS), donde:

- Variable dependiente:
 - desempleo
- Variables independientes:
 - inflación
 - crecimiento del PIB

El modelo fue estimado utilizando la librería [statsmodels](#).

5.4 Modelos predictivos

Posteriormente se desarrollaron distintos modelos predictivos utilizando [scikit-learn](#).

Modelos construidos

1. Modelo base
 - inflación
 - crecimiento del PIB
2. Modelo con [lag1](#)
 - inflación
 - crecimiento del PIB
 - desempleo rezagado un período
3. Modelo con [lag1 + lag2](#)
 - inflación
 - crecimiento del PIB
 - desempleo rezagado uno y dos períodos
4. Random Forest Regressor

5.5 Validación temporal

Debido a la naturaleza temporal de los datos, se utilizó una división cronológica:

- 80% entrenamiento
- 20% prueba

Esto permitió evitar fuga de información temporal y evaluar de forma más realista el desempeño predictivo.

6. Resultados econométricos

El modelo OLS presentó los siguientes resultados generales:

- $R^2 \approx 0.49$
- inflación significativa estadísticamente
- crecimiento del PIB significativo estadísticamente

Los coeficientes estimados mostraron relaciones negativas entre desempleo e inflación, así como entre desempleo y crecimiento del PIB.

Esto implica que:

- mayores niveles de inflación estuvieron asociados a menores niveles de desempleo,
- mayores tasas de crecimiento económico estuvieron asociadas a menores niveles de desempleo.

Estos resultados son coherentes con teorías macroeconómicas tradicionales, particularmente con la relación entre actividad económica y empleo.

7. Resultados predictivos

7.1 Comparación de modelos

Modelo	MAE	RMSE
Base	3.25	4.22
Lag1	1.82	2.09
Lag1 + Lag2	2.01	2.23
Random Forest	3.36	4.30

7.2 Interpretación

El modelo con **lag1** presentó el mejor desempeño predictivo, reduciendo significativamente tanto el MAE como el RMSE respecto al modelo base.

La incorporación de un segundo rezago (**lag2**) no mejoró los resultados, lo que sugiere que el comportamiento reciente del desempleo es más relevante que dinámicas temporales más largas dentro de esta muestra.

Por otro lado, Random Forest presentó un desempeño inferior al modelo lineal con rezago.

8. Resultados de Random Forest

El análisis de importancia de variables mostró:

Variable	Importancia
inflación	0.62
unemployment_lag1	0.31
gdp growth	0.07

Esto indica que:

- la inflación fue la variable más influyente dentro del modelo,
- el desempleo rezagado también tuvo una importancia considerable,
- el crecimiento del PIB tuvo menor relevancia relativa

9. Discusión

Los resultados permiten extraer varias conclusiones importantes.

En primer lugar, el desempleo presenta una clara persistencia temporal, lo que explica la mejora observada al incorporar **lag1**.

En segundo lugar, el hecho de que Random Forest no superará al modelo lineal sugiere que:

- el conjunto de datos es relativamente pequeño,
- la estructura del problema puede ser captada adecuadamente mediante relaciones lineales,
- y modelos más complejos no necesariamente producen mejores predicciones en contextos con muestras reducidas.

Esto evidencia una lección importante dentro de ciencia de datos:

la complejidad algorítmica no garantiza automáticamente mejores resultados.

10. Limitaciones

El proyecto presenta varias limitaciones:

- tamaño de muestra reducido,
- pocas variables explicativas,
- posible presencia de autocorrelación,
- ausencia de variables institucionales o externas,
- limitaciones inherentes al uso de datos anuales.

11. Líneas futuras de investigación

Como posibles extensiones del proyecto se propone:

- implementar walk-forward validation,
- desarrollar modelos ARIMA y SARIMA,
- incorporar variables adicionales,
- explorar modelos boosting como XGBoost,
- utilizar datos trimestrales o mensuales,
- aplicar técnicas de series de tiempo más avanzadas.

12. Conclusiones

El proyecto permitió integrar herramientas de econometría y Machine Learning para analizar y predecir el desempleo en Costa Rica utilizando Python.

Los resultados mostraron que:

- inflación y crecimiento del PIB presentan relaciones significativas con el desempleo,
- la incorporación de memoria temporal mejora considerablemente la capacidad predictiva,
- y modelos simples bien especificados pueden superar a algoritmos más complejos cuando la muestra es limitada.

El mejor desempeño fue obtenido por el modelo lineal con `lag1`, mientras que Random Forest no logró mejorar los resultados.

En conjunto, el estudio demuestra el valor de combinar análisis económico con herramientas modernas de ciencia de datos, así como la importancia de evaluar críticamente el desempeño de distintos modelos predictivos.

13. Herramientas utilizadas

- Python
- Jupyter Notebook
- pandas
- numpy
- requests
- matplotlib
- statsmodels
- scikit-learn

14. Referencias

- Banco Mundial. World Development Indicators.
- McKinney, Wes. Python for Data Analysis. 3rd ed.
- VanderPlas, Jake. Python Data Science Handbook.
- Hastie, Tibshirani y Friedman. The Elements of Statistical Learning.